

# MeanShift, HMM, MACE, SVM


doc. Ing. Josef Chaloupka, Ph.D.



# MeanShift

- MeanShift – přesun za průměrem
- patří mezi shlukovací (clusterovací) segmentační metody
- Bezparametrické – není potřeba znát počet nebo tvar segmentů
- iterativní algoritmus >>> v každé iteraci se vypočte vážený průměr okna a do tohoto okna se nové okno posune. Dosažení konvergence (další posun = 0) – konec. Posun jen v úrovni 1px – ukončení při určitém počtu interací nebo po dosažení malého (předem daného) posunu.
- Body v prostoru jsou reprezentovány vektorem  $\mathbf{X}_i = [x, y, f(y, x)]$ ;  $x, y$  souřadnice bodu,  $f(y, x)$  – např. jas (3D), RGB + 3 parametry – (5D)
- Algoritmus – 3 parametry: 1) poloměr výpočetního okna, 2) jádro (kernel)  $K$ , 3) maximální jasová vzdálenost

# MeanShift



interace

# MeanShift

- MeanShift – sledování objektů



[https://docs.opencv.org/3.4/d7/d00/tutorial\\_meanshift.html](https://docs.opencv.org/3.4/d7/d00/tutorial_meanshift.html)

# MeanShift



Backhouse, I. Y. H. Gu and T. Wang, "ML Nonlinear Smoothing for Image Segmentation and its Relationship to the Mean Shift," *2007 IEEE International Conference on Image Processing*, San Antonio, TX, USA, 2007, pp. IV - 337-IV - 340

# MeanShift

- Body v prostoru jsou reprezentovány vektorem  $\mathbf{X}_i = [x, y, f(y, x)]$ ;  $x, y$  souřadnice bodu,  $f(y, x)$  – např. jas (3D)  $d = 3$ , RGB + 3 parametry – (5D)  $d = 5$
- Algoritmus – 3 parametry: 1) poloměr výpočetního okna  $h$ , 2) jádro (kernel)  $K$ , 3) maximální jasová vzdálenost
- Obrazové body blízko u sebe se stejnou intenzitou budou v prostoru (3D, 5D) vytvářet shluky
- V každém kroku algoritmu se z vybraného bodu posunujeme ve směru váženého průměru (nového těžiště)
- Postup: 1) z každého bodu pustíme MeanShift a uložíme si lokální max., kam algoritmus dokonvergoval, 2) Shlukneme body, které dokonvergovaly do stejného místa (s jistou tolerancí)
- Odhad hustoty v bodě  $x$ :
$$f(\mathbf{x}) = \frac{1}{nh^d} \sum_{i=1}^n K \left( \frac{\mathbf{x} - \mathbf{x}_i}{h} \right)$$

$h$  – šířka kernelu,  $x_{1..n}$  jsou vzorky

# MeanShift

- K – kernel (jádro) – radiálně symetrická funkce  $K(\mathbf{x}) = c_k k(\|\mathbf{x}\|^2)$

- k – profil kernelu


- Představa 2D – kruh, poloměr h, 3D koule, ND – ND koule

$$K(x - x_i) = \begin{cases} 1 & \text{if } \|x - x_i\| \leq h \\ 0 & \text{if } \|x - x_i\| > h \end{cases}$$

- Uniformní kernel  $K(x) = 0,5$   
pro  $\{|x| \leq 1\}$ , jinak 0

- Epanechnikův kernel  $K(x) = (3 / 4)^* (1 - x^2)$   
pro  $\{|x| \leq 1\}$ , jinak 0

- Gaussův kernel  $K(x) = \frac{1}{\sqrt{2\pi}} e^{-0,5 x^2}$





# MeanShift

- Hustota pravděpodobnosti není tak důležitá, důležitý je její gradient:

$$\begin{aligned}\nabla f(\mathbf{x}) &= \frac{2c_k}{nh^d} \sum_{i=1}^n (\mathbf{x} - \mathbf{x}_i) k' \left( \left\| \frac{\mathbf{x} - \mathbf{x}_i}{h} \right\|^2 \right) \\ &= \frac{2c_k}{nh^d} \left[ \sum_{i=1}^n g \left( \left\| \frac{\mathbf{x} - \mathbf{x}_i}{h} \right\|^2 \right) \right] \left[ \frac{\sum_{i=1}^n \mathbf{x}_i g \left( \left\| \frac{\mathbf{x} - \mathbf{x}_i}{h} \right\|^2 \right)}{\sum_{i=1}^n g \left( \left\| \frac{\mathbf{x} - \mathbf{x}_i}{h} \right\|^2 \right)} - \mathbf{x} \right] \quad g(x) = -k'(x)\end{aligned}$$

- Postupujeme z bodu  $\mathbf{x}$  ve směru gradientu dokud změna posunu není menší než námi zvolený práh,  $\mathbf{x}_{j+1} - \mathbf{x}_j$  **meanshift krok**

while(1)  
     $\mathbf{x}_{j+1} = \dots$   
     $i = i + 1$   
    if  $\| \mathbf{x}_{j+1} - \mathbf{x}_j \| < T$  break

$$\mathbf{x}_{j+1} = \frac{\sum_{i=1}^n \mathbf{x}_i g \left( \left\| \frac{\mathbf{x}_i - \mathbf{x}_j}{h} \right\|^2 \right)}{\sum_{i=1}^n g \left( \left\| \frac{\mathbf{x}_i - \mathbf{x}_j}{h} \right\|^2 \right)}$$


- Segmentace – shlukování bodů: pro každý bod máme spočítané lokální maximum (atraktor)  $z = [x, y, f(y, x)]$ , sousední body A a B sloučíme pokud  $\text{abs}(z_A - z_B) \leq t$



# MeanShift

- **Nastavení algoritmu**
- K – kernel nejmenší vliv
- Minimální jasová vzdálenost – nutnost nastavit
- Poloměr výpočetního okna – velký vliv na výpočet (čas), špatně zvolen – špatná segmentace
- Zastavit včas algoritmus – nespoléhat, že při konvergenci posun = 0, zastavit dříve při malém posunu, nastavit maximální počet interakcí
- Stejnobarevné plochy tvořené více atraktory, sloučení atraktorů dle minimální jasové vzdálenosti
- Modifikace Meanshift – 1) zlepšení segmentační schopnosti – volba vyhlazovacích parametrů, 2) zrychlení výpočtu – zjednodušení vyhledávání sousedních bodů, omezení počtu interakcí...





# HMM - Hidden Markov Model



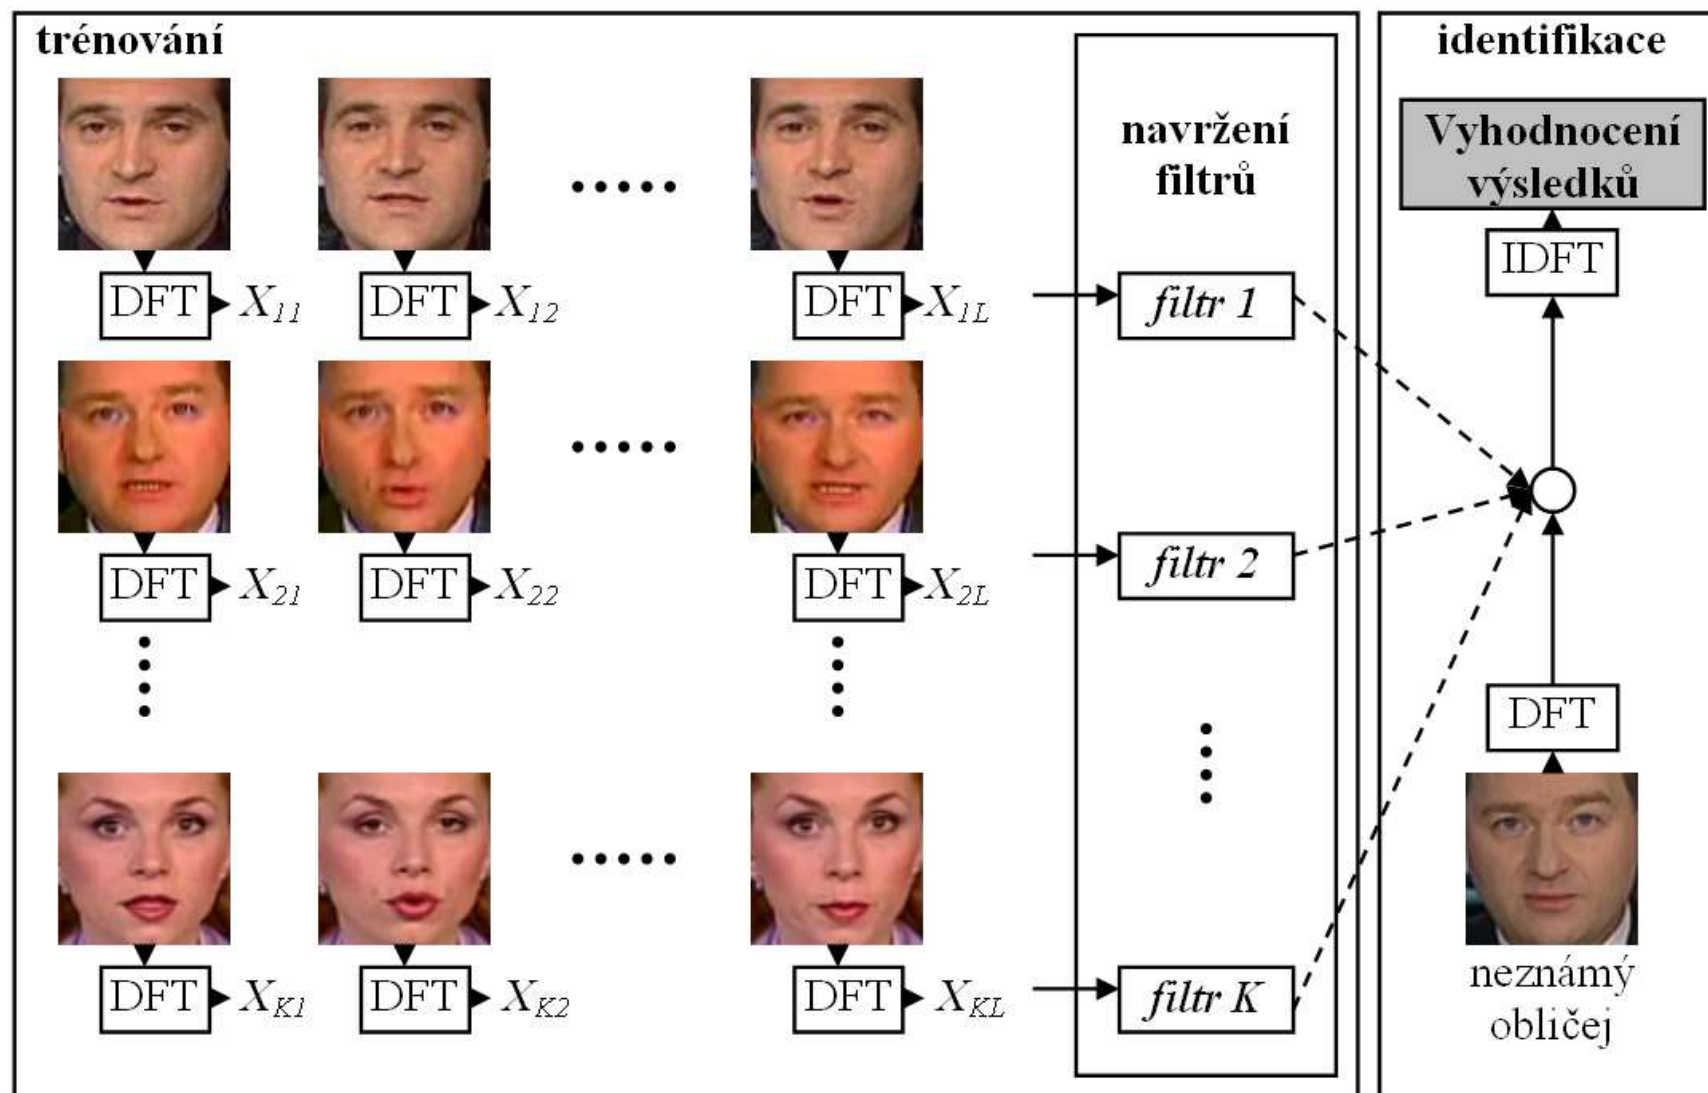
$$b_s(\vec{x}) = \sum_{m=1}^M c_{sm} \frac{1}{\sqrt{(2\pi)^P \det \Sigma_{sm}}} \cdot \exp \left[ -0.5 (\vec{x} - \vec{\bar{x}}_{sm})^T \Sigma_{sm}^{-1} (\vec{x} - \vec{\bar{x}}_{sm}) \right]$$

$$b_s(\vec{x}) = \prod_{t=1}^T \left( \sum_{m=1}^M c_{stm} \frac{1}{\sqrt{(2\pi)^P \det \Sigma_{stm}}} \cdot \exp \left[ -0.5 (\vec{x} - \vec{\bar{x}}_{stm})^T \Sigma_{stm}^{-1} (\vec{x} - \vec{\bar{x}}_{stm}) \right] \right)^{\gamma_t}$$

# HMM - Hidden Markov Model



# MACE - Minimum Average Correlation Energy



# MACE - Minimum Average Correlation Energy

**Návrh filtru MACE**  $H = D^{-1} X (X^+ D^{-1} X)^{-1} u$

X – matice z vektorů: DFT počítaná z trénovacích obrazů, lexikograficky řazené

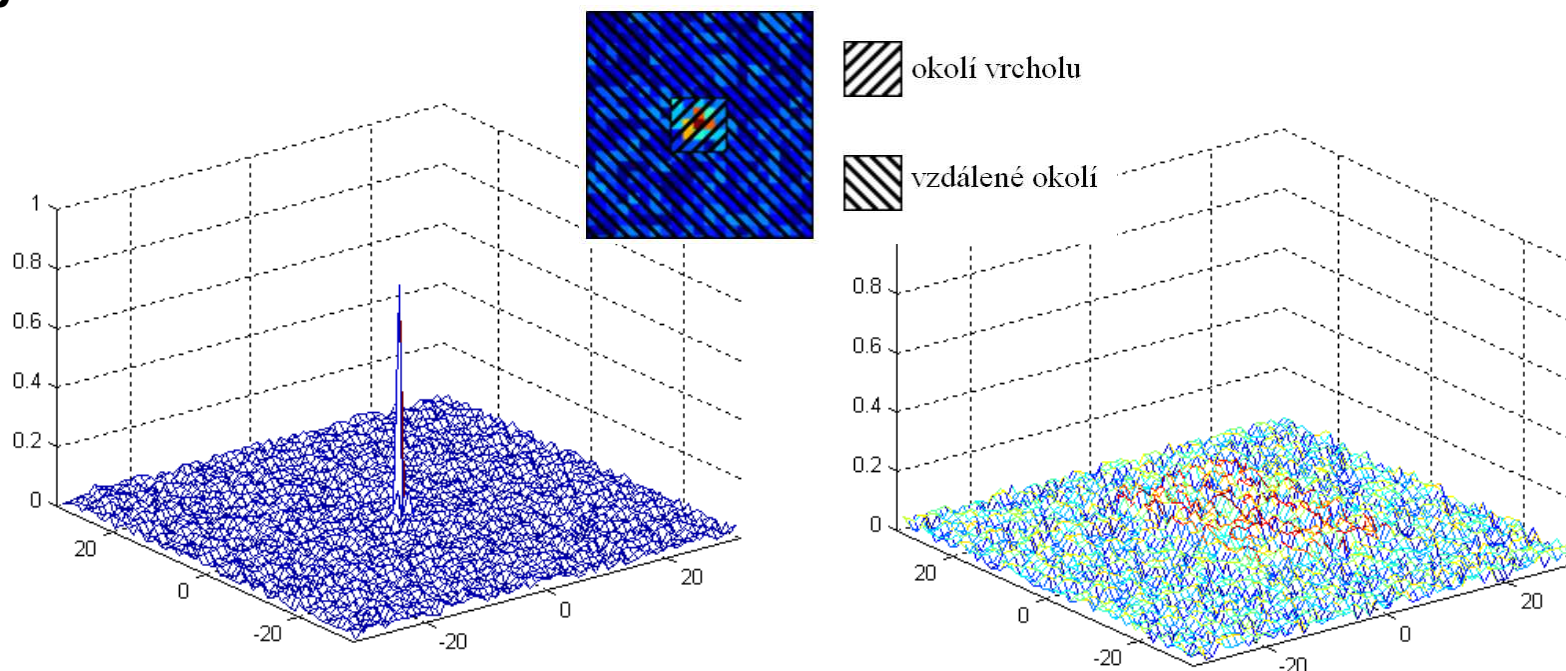
X<sup>+</sup> – matice transponovaná a komplexně sdružená k X

u – sloupcový vektor, hodnoty obvykle 1

D – diagonální matice: hodnoty spočítané jako průměr výkonového spektra z řádků matice X

$$d_{jj} = \frac{1}{L} \sum_{i=1}^L |x_i(j)|^2 \quad j = 1, \dots, N$$

**Vyhodnocení**


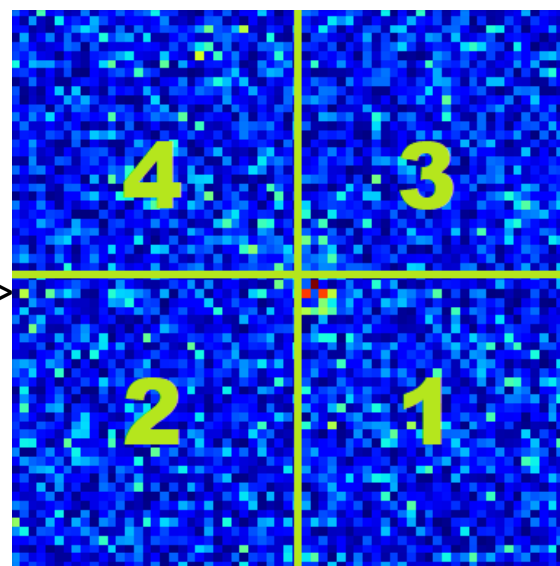
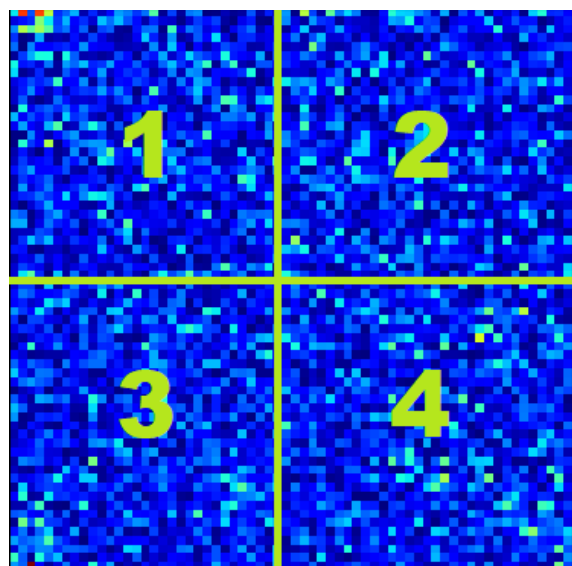


# MACE - Minimum Average Correlation Energy

**příklad:** 3 třídy (různí lidé), 3 snímky (64x64) od každého -> 3 filtry

Návrh filtru MACE  $H = D^{-1} X (X^+ D^{-1} X)^{-1} u$

$$\begin{array}{ccccccc}
 \boxed{\phantom{00000000}} & * & \boxed{\phantom{00000000}} & * & \left( \boxed{\phantom{00000000}} * \boxed{\phantom{00000000}} * \boxed{\phantom{00000000}} \right)^{-1} & * & \boxed{\phantom{00000000}} \\
 D^{-1} & & X & & X^+ & & D^{-1} & & X & & u & = & H_i & u = \begin{bmatrix} 1 \\ 1 \\ 1 \end{bmatrix} & \boxed{\phantom{00000000}} & = & \boxed{\phantom{00000000}} \cdot \boxed{\phantom{00000000}} \\
 (4096 \times 4096) & & (4096 \times 3) & & (3 \times 4096) & & (4096 \times 4096) & & (4096 \times 3) & & (3 \times 1) & & (4096 \times 1) & & R_i = X_u \cdot H_i, i = 1 \dots 3
 \end{array}$$




okolí vrcholu  
vzdálené okolí

okolí (O) 20x20, vrchol (V) 10x10

$$RES_i = \frac{\max(V) - \text{mean}(O \text{ (bez V)})}{\text{std}(O \text{ (bez V)})}$$

# MNIST dataset

- Modified National Institute of Standards and Technology database (1994)
- 60 000 obrázků pro trénink, 10 000 pro testování





# MNIST dataset

Type	Classifier	Distortion	Preprocessing	Error rate (%)
Linear classifier	Pairwise linear classifier	None	Deskewing	7.6 <sup>[10]</sup>
Decision stream with Extremely randomized trees	Single model (depth > 400 levels)	None	None	2.7 <sup>[28]</sup>
K-Nearest Neighbors	K-NN with rigid transformations	None	None	0.96 <sup>[29]</sup>
K-Nearest Neighbors	K-NN with non-linear deformation (P2DHMDM)	None	Shiftable edges	0.52 <sup>[30]</sup>
Boosted Stumps	Product of stumps on Haar features	None	Haar features	0.87 <sup>[31]</sup>
Non-linear classifier	40 PCA + quadratic classifier	None	None	3.3 <sup>[10]</sup>
Random Forest	Fast Unified Random Forests for Survival, Regression, and Classification (RF-SRC) <sup>[32]</sup>	None	Simple statistical pixel importance	2.8 <sup>[33]</sup>
Support-vector machine (SVM)	Virtual SVM, deg-9 poly, 2-pixel jittered	2002	Deskewing	0.56 <sup>[34]</sup>
Neural network	2-layer 784-800-10	None	None	1.6 <sup>[35]</sup>
Neural network	2-layer 784-800-10	2003	Elastic distortions	0.7 <sup>[35]</sup>
Deep neural network (DNN)	6-layer 784-2500-2000-1500-1000-500-10	2010	Elastic distortions	0.35 <sup>[36]</sup>
Convolutional neural network (CNN)	6-layer 784-40-80-500-1000-2000-10	None	Expansion of the training data	0.31 <sup>[37]</sup>
Convolutional neural network	6-layer 784-50-100-500-1000-10-10	None	Expansion of the training data	0.27 <sup>[38]</sup>
Convolutional neural network (CNN)	13-layer 64-128(5x)-256(3x)-512-2048-256-256-10	None	None	0.25 <sup>[22]</sup>
Convolutional neural network	Committee of 35 CNNs, 1-20-P-40-P-150-10	Elastic distortions	Width normalizations	0.23 <sup>[17]</sup>
Convolutional neural network	Committee of 5 CNNs, 6-layer 784-50-100-500-1000-10-10	None	Expansion of the training data	0.21 <sup>[24][25]</sup>
Random Multimodel Deep Learning (RMDL)	10 NN-10 RNN - 10 CNN	None	None	0.18 <sup>[27]</sup>
Convolutional neural network	Committee of 20 CNNS with Squeeze-and-Excitation Networks <sup>[39]</sup>	None	Data augmentation	0.17 <sup>[40]</sup>
Convolutional neural network	Ensemble of 3 CNNs with varying kernel sizes	2020	Data augmentation consisting of rotation and translation	0.09 <sup>[41]</sup>

[https://en.wikipedia.org/wiki/MNIST\\_database](https://en.wikipedia.org/wiki/MNIST_database)

# SVM - Support vector machines

- Vladimir Naumovich Vapnik (\* 1936), Rusko, 1990 - AT&T Bell Labs (USA)

- metoda podpůrných vektorů


- Základní metoda – lineární klasifikace do dvou tříd

- Cíl -> nalézt nadrovinu, která prostor příznaků optimálně rozdělí -> trénovací data náležející odlišným třídám leží v opačných poloprostorech

- Optimální nadrovina -> hodnota minima vzdáleností příznaků od roviny je co největší, okolo nadroviny (na obě strany) je co nejširší pruh bez příznaků


- Maximální odstup (*maximal margin*) - pásmo necitlivosti, hraniční pásmo

- Pro popis nadroviny stačí hraniční příznaky, těch bývá malé množství – podpůrné vektory (support vectors)



# SVM - Support vector machines

- Trénovací dataset  $(\mathbf{x}_1, y_1) \dots (\mathbf{x}_n, y_n) \gg \mathbf{x} = (x_1, x_2)$ ,  $y = 1$  nebo  $-1$  (dle třídy)
- Optimální nadrovina  $\rightarrow$  hodnota minima vzdáleností  $\mathbf{x}_i$  od roviny je co největší
- Nadrovina  $\mathbf{w} \cdot \mathbf{x} - b = 0$
- $\mathbf{w}$  normála nadroviny,  $\|\mathbf{w}\|$  Euklidovská norma
- $|b| / \|\mathbf{w}\|$  vzdálenost nadroviny od počátku souřadnic
- Nejkratší vzdálenost nejbližšího bodu z (1)  $d_+$  a (-1)  $d_-$ ,  $d_+ + d_-$  je šířka hraničního pásma
- body na hranici hraničního pásma jsou podpůrné vektory, pokud je odebereme, tak se změní Poloha optimální nadroviny



# SVM - Support vector machines

- Trénovací dataset  $(\mathbf{x}_1, y_1) \dots (\mathbf{x}_n, y_n) \gg \mathbf{x} = (x_1, x_2)$ ,  $y = 1$  nebo  $-1$  (dle třídy)

$$\mathbf{x}_i \cdot \mathbf{w} - b \geq +1 \text{ pro } y_i = +1$$

$$\mathbf{x}_i \cdot \mathbf{w} - b \leq -1 \text{ pro } y_i = -1$$

$\gg$

$$y_i(\mathbf{x}_i \cdot \mathbf{w} - b) - 1 \geq 0$$


- body ( $y_i = +1$ ) kde platí  $= 1$ , leží v nadrovině  $H_1$

$$\mathbf{w} \cdot \mathbf{x} - b = 1$$

- body ( $y_i = -1$ ) kde platí  $= -1$ , leží v nadrovině  $H_2$

$$\mathbf{w} \cdot \mathbf{x} - b = -1$$

- nadroviny  $H_1$  a  $H_2$  jsou kolmé na normálový vektor  $\mathbf{w}$ , vzdálenost od rozdělovací nadroviny je  $1 / \|\mathbf{w}\|$ , dohromady  $2 / \|\mathbf{w}\|$



# SVM - Support vector machines

- Trénovací dataset  $(\mathbf{x}_1, y_1) \dots (\mathbf{x}_n, y_n) \gg \mathbf{x} = (x_1, x_2), y = 1 \text{ nebo } -1 \text{ (dle třídy)}$

## Neseparabilní případ - Soft-margin (Hard-margin)


$\gg \gg$  minimalizace chyby,  $E \geq 0$

$$\mathbf{x}_i \cdot \mathbf{w} - b \geq +1 - E_i \text{ pro } y_i = +1$$

$$\mathbf{x}_i \cdot \mathbf{w} - b \leq -1 - E_i \text{ pro } y_i = -1$$




$$\min_{\mathbf{w}, \xi} \left\{ \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_{i=1}^n \xi_i \right\}$$

- C volitelný parametr, větší C = větší penalizace chyb



# SVM - Support vector machines

**Nelineární SVM** >>> jádrový trik (kernel trick)  
transformace dat do prostoru vyšší dimenze,  
kde jsou data lineárně separabilní



Support Vector Machine (SVM) in 2 minutes: [https://youtu.be/\\_YPScrckx28](https://youtu.be/_YPScrckx28)



# SVM - Support vector machines

- Řešení (**trénování**)>>> analytické řešení >>> jen pokud máme málo dat, nebo jsme schopni určit, které příznaky budou podpůrnými vektory
- Data jsou většinou zašuměná - Neseeparabilní případ - Soft-margin >>> numerické řešení + speciální metody programování (kvadratického programování s lineárními vazbovými podmínkami, "hroudová" metoda (chunking method)
- Lagrangeova formulace SVM – namísto  $y_i (\mathbf{x}_i \cdot \mathbf{w} - b) - 1 \geq 0$  jsou využity Lagrangeovy multiplikátory
- Karushovy-Kuhnovy-Tuckerovy (KKT) podmínky >>> pro optimální řešení v úloze nelineárního programování
- **Testování** (klasifikace, identifikace, rozpoznávání) – neznámý objekt – parametry  $\mathbf{x} = (x_1, x_2)$  spočítáme  $\text{sgn}(\mathbf{w} \cdot \mathbf{x} + b)$  a dle znaménka zařadíme do jedné ze tříd
- Využití SVM: dobře parametrizovatelné objekty, identifikace obličejů, OCR, bioinformatika (klasifikace proteinů), regresní analýza
- + oproti ANN vždy po trénování nalezeno řešení, malý počet parametrů, poměrně rychlé
- - u rozsáhlé úlohy (miliony podpůrných vektorů) >>> velké nároky na paměť a rychlost

<https://scikit-learn.org/stable/modules/svm.html>